Informe De Ejercicios De Clustering

María Isabel Hernández Bello

Universidad de Cundinamarca

Introducción al Machine Learning

Mónica María Fonseca Vigoya

Noviembre de 2026

Contenido

Resumen 3
1. Introducción y objetivo 3
2. Datos y preprocesamiento 3
3. Métodos de clustering 4
3.1 K-means 4
3.2 DBSCAN 4
3.3 Clustering jerárquico 4
4. Resultados y comparación 5
4.1 Perfil de los grupos 5
4.2 Proyección PCA 6
5. Análisis y discusión 7
6. Conclusiones 8
7. Código fuente y guía de ejecución 8
8. Referencias 9
9. Anexos 9

Resumen

Este informe desarrolla y compara tres técnicas de clustering —K-means, DBSCAN y agrupamiento jerárquico— sobre el conjunto de datos de deserción educativa de establecimientos de Medellín correspondiente a 2017, publicado en MEData. La base contiene 1.134 registros y 52 columnas. Para el modelado se seleccionaron 46 variables numéricas de matrícula y deserción; se eliminaron dos variables constantes y se estandarizaron las 44 restantes. K-means se ajustó con tres grupos; DBSCAN se evaluó con distintas combinaciones y se seleccionó eps=5 y min_samples=5; el método jerárquico se configuró con tres grupos. El mayor coeficiente Silhouette correspondió al modelo jerárquico (0,5658), seguido de DBSCAN (0,5555) y K-means (0,4435). DBSCAN obtuvo el menor índice Davies-Bouldin (0,7014), aunque clasificó 105 registros como ruido. Las diferencias entre grupos se asociaron principalmente con los volúmenes de matrícula, en especial de grados CLEI. Se concluye que el clustering permite explorar perfiles, pero el desequilibrio de tamaños y la naturaleza agregada y anual de los datos limitan la generalización de los hallazgos.

1. Introducción y objetivo

El clustering es una técnica de aprendizaje no supervisado que agrupa observaciones según su semejanza, sin utilizar una variable objetivo-etiquetada. Su aplicación permite explorar estructuras internas, reconocer perfiles y detectar observaciones atípicas. El objetivo de este ejercicio es aplicar K-means, DBSCAN y clustering jerárquico a los registros de matrícula y deserción educativa, comparar sus métricas y analizar los grupos identificados.

2. Datos y preprocesamiento

La fuente es el conjunto “Deserción educativa” de MEData, con información de establecimientos educativos de Medellín para 2017. La base analizada contiene 1.134 filas y 52 columnas. Incluye datos de identificación y contexto (año, código DANE, establecimiento, sector, comuna y sexo),

además de conteos de deserción y matrícula por grado y modalidad. La revisión inicial encontró cero valores faltantes y cero registros duplicados.

Se seleccionaron 46 variables numéricas con prefijos desercion_ y matricula_. Se excluyeron las variables identificadoras y categóricas. Se detectaron y eliminaron dos variables constantes: desercion_grado_12 y desercion_grado_13. El conjunto final quedó con 44 variables y 1.134 registros. Se aplicó StandardScaler para llevar las variables a una escala comparable, con promedio cercano a cero y desviación estándar cercana a uno.

3. Métodos de clustering

3.1 K-means

K-means asigna cada observación al centroide más cercano y minimiza la variabilidad interna de los grupos. Se exploraron valores de K entre 2 y 10 mediante inercia y Silhouette. Se seleccionó K=3, con n_init=20 y random_state=42. Los grupos tuvieron 839, 280 y 15 registros. Métricas: Silhouette=0,4435; Davies-Bouldin=1,1627; Calinski-Harabasz=295,66.

3.2 DBSCAN

DBSCAN identifica regiones densas y permite marcar como ruido las observaciones que no cumplen el criterio de densidad. Se exploraron distintos valores de eps y min_samples, apoyándose en la gráfica de distancias a los cinco vecinos más cercanos. La configuración seleccionada fue eps=5 y min_samples=5. Se identificaron dos grupos, con 1.024 y 5 registros, y 105 registros como ruido (9,26 %). Métricas reportadas: Silhouette=0,5555; Davies-Bouldin=0,7014; Calinski-Harabasz=28,28. Las métricas se interpretan con cautela por el tamaño reducido del segundo grupo.

3.3 Clustering jerárquico

El agrupamiento jerárquico aglomerativo fusiona progresivamente las observaciones más próximas. Se evaluaron soluciones entre dos y ocho grupos. Se seleccionó una solución de tres clústeres, con enlace Ward y distancia euclidiana sobre los datos estandarizados. Los grupos tuvieron 1.024, 100 y 10 registros. Métricas: Silhouette=0,5658; Davies-Bouldin=1,1521; Calinski-Harabasz=235,8415.

4. Resultados y comparación

Algoritmo	Grupos	Ruido	Silhouette	Davies-Bouldin	Calinski-Harabasz
K-means	3	0	0,4435	1,1627	295,6600
DBSCAN	2	105	0,5555	0,7014	28,2800
Jerárquico	3	0	0,5658	1,1521	235,8415

Silhouette evalúa cohesión y separación: cuanto mayor, mejor. Davies-Bouldin se interpreta mejor cuanto menor, mientras que Calinski-Harabasz suele ser mejor cuanto mayor. El método jerárquico alcanzó el mayor Silhouette (0,5658); DBSCAN obtuvo el menor Davies-Bouldin (0,7014), y K-means el mayor Calinski-Harabasz (295,66). Por tanto, no hay un ganador absoluto en todas las métricas.

4.1 Perfil de los grupos

En K-means, el grupo 0 reunió 73,99 % de los registros, el grupo 1 el 24,69 % y el grupo 2 el 1,32 %. Las mayores diferencias se observaron en matrícula de CLEI 4, CLEI 5 y CLEI 6, seguidas por matrícula de los grados 6, 7, 5, 3 y 4. El grupo 1 estuvo compuesto principalmente por establecimientos oficiales (90,7 %), mientras que el grupo 2 concentró una proporción alta de cobertura contratada (66,7 %). La distribución por sexo fue relativamente equilibrada.

En DBSCAN, el 9,26 % de los registros fue clasificado como ruido. El grupo principal concentró el 90,30 % y el segundo grupo solo el 0,44 %. Las diferencias más marcadas también se asociaron con matrícula de CLEI 4, CLEI 3 y CLEI 6. El grupo de cinco registros no debe interpretarse como un perfil generalizable.

En el modelo jerárquico, el grupo principal representó 90,30 %, el segundo 8,82 % y el tercero 0,88 %. Las diferencias más importantes correspondieron a matrícula de CLEI 5, CLEI 4, CLEI 6 y CLEI 3. El segundo grupo presentó promedios de deserción superiores en varios grados frente al grupo

principal, aunque está formado por 100 registros. El tercer grupo contiene diez registros y requiere cautela.

4.2 Proyección PCA

Se aplicó PCA únicamente como recurso de proyección visual a dos dimensiones. Los dos primeros componentes explicaron 49,84 % de la varianza total. Las gráficas permiten comparar visualmente las etiquetas de los tres algoritmos, pero la proyección no conserva toda la información de las 44 variables y no debe ser la única evidencia para juzgar la calidad de los clústeres.

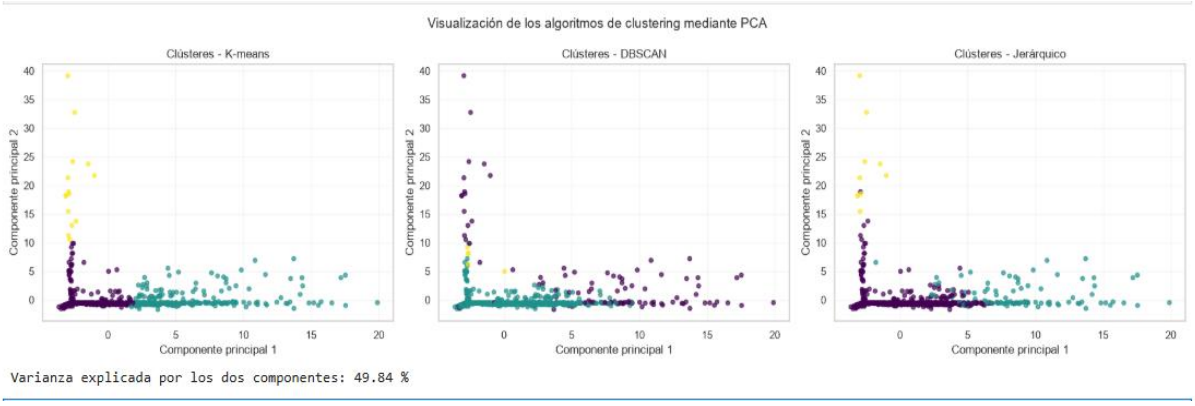


Figura 1. Visualización de los tres algoritmos de clustering mediante los dos primeros componentes PCA.

COMPARACIÓN DE RESULTADOS:

	Algoritmo	Clusters	Registros en ruido	Silhouette	Davies-Bouldin	Calinski-Harabasz
0	K-means	3	0	0.4435	1.1627	295.6600
1	DBSCAN	2	105	0.5555	0.7014	28.2800
2	Jerárquico	3	0	0.5658	1.1521	235.8415

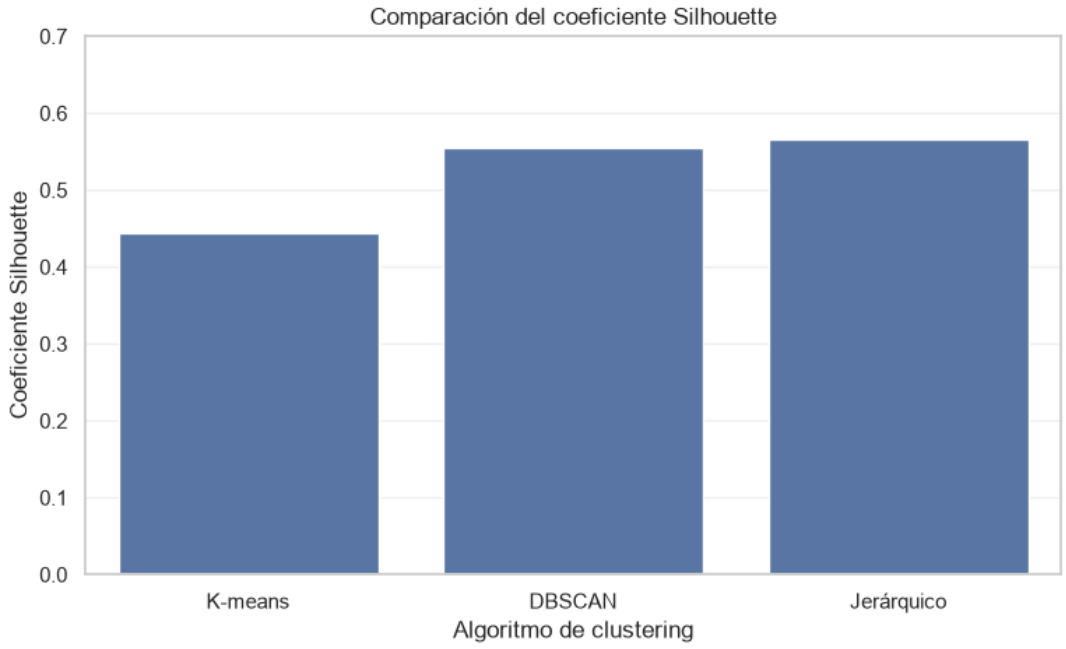


Figura 2. Comparación del coeficiente Silhouette entre los algoritmos.

5. Análisis y discusión

Los tres algoritmos identificaron un grupo predominante y uno o más grupos pequeños. Esto indica que numerosos registros comparten perfiles semejantes en los conteos de matrícula y deserción, mientras que otros presentan combinaciones diferentes. La matrícula, especialmente la de modalidades CLEI, fue una de las variables que más diferenció los grupos. Los resultados describen patrones en registros agregados, no comportamientos individuales.

La solución jerárquica obtuvo el mayor Silhouette, aunque incluye un clúster de solo diez registros. DBSCAN obtuvo el menor Davies-Bouldin y detectó observaciones atípicas, pero su segundo grupo contiene cinco registros. K-means ofrece una partición sencilla y reproducible, aunque su Silhouette fue menor. La elección del algoritmo depende del propósito del análisis y debe considerar simultáneamente métricas, tamaños y utilidad interpretativa.

Las limitaciones principales son el uso de un solo año (2017), la naturaleza agregada de los datos y el desequilibrio en los tamaños de los grupos. Cada fila corresponde a una combinación de establecimiento y sexo, no a un estudiante individual. Los conteos absolutos también pueden estar influidos por el tamaño de cada establecimiento. Un análisis posterior podría incorporar varios años y estudiar tasas normalizadas por matrícula, definiendo cuidadosamente los denominadores.

6. Conclusiones

La aplicación de K-means, DBSCAN y clustering jerárquico permitió explorar perfiles diferenciados en los datos de matrícula y deserción. El modelo jerárquico alcanzó el mayor Silhouette (0,5658), DBSCAN obtuvo el menor Davies-Bouldin (0,7014) e identificó 105 registros como ruido, y K-means presentó el mayor Calinski-Harabasz (295,66).

Las variables de matrícula, especialmente las asociadas a grados CLEI, mostraron las diferencias más importantes entre grupos. El desequilibrio de tamaños obliga a interpretar con precaución los clústeres pequeños. Se recomienda ampliar el análisis a otros años, trabajar con tasas además de conteos absolutos y validar la estabilidad de los grupos antes de utilizar los resultados para orientar decisiones educativas.

7. Código fuente y guía de ejecución

El proyecto adjunto incluye un notebook y un script reproducible. Para ejecutarlos se requiere Python 3.10 o superior y las dependencias indicadas en requirements.txt. El código descarga el CSV de MEData, selecciona las variables, elimina constantes, estandariza los datos, entrena los tres algoritmos, calcula métricas y genera visualizaciones.

Instalar dependencias: pip install -r requirements.txt

Ejecutar script: python clustering_desercion_educativa.py

Abrir notebook: jupyter notebook Clustering_Desercion_Educativa.ipynb

Enlace GitHub: MariaHernandezBello/proyecto-clustering-desercion-educativa: Análisis de clustering aplicado a datos de deserción educativa de Medellín mediante K-means, DBSCAN y clustering jerárquico.

8. Referencias

Alcaldía de Medellín. (s. f.). Deserción educativa [Conjunto de datos]. MEData. https://medata.app.medellin.gov.co/sites/default/files/distribution/1-011-08-000065/desercion_educativa.csv

scikit-learn developers. (s. f.). Clustering. https://scikit-learn.org/stable/modules/clustering.html

scikit-learn developers. (s. f.). Metrics and scoring: quantifying the quality of predictions. https://scikit-learn.org/stable/modules/model_evaluation.html

9. Anexos

El notebook y el script contienen las secciones de carga, selección y limpieza, estandarización, modelado, evaluación, análisis de perfiles y visualización PCA.

	Número de clústeres	Inercia	Silhouette
0	2	39077.2178	0.4220
1	3	32765.4983	0.4435
2	4	28939.6545	0.3361
3	5	26921.1615	0.3358
4	6	25359.2227	0.3440
5	7	23918.5575	0.3529
6	8	22809.3750	0.3621
7	9	21671.1634	0.3353
8	10	20409.3396	0.3337

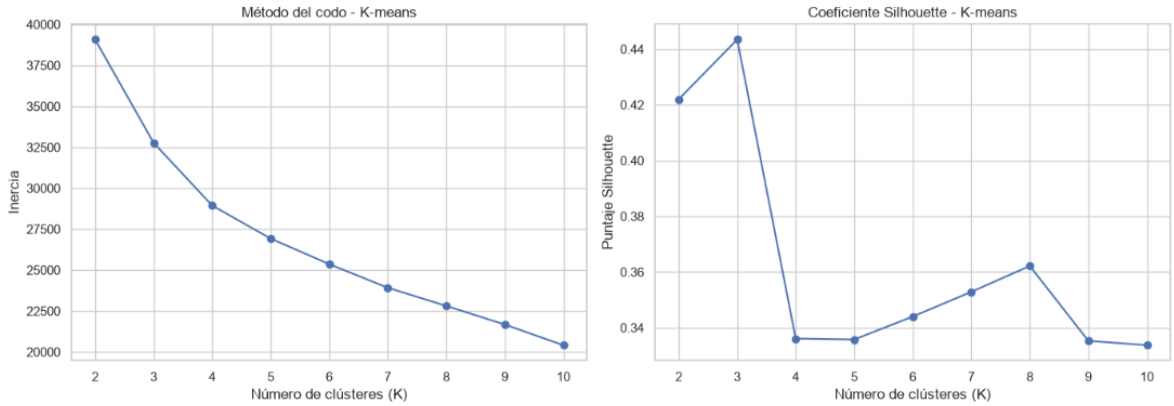
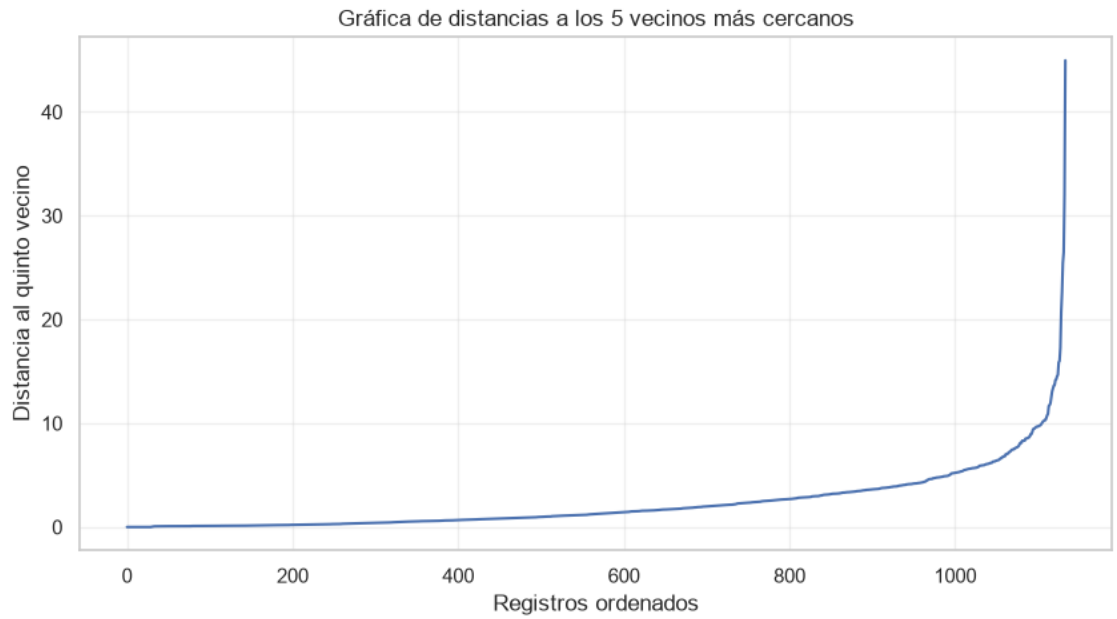


Figura 3. Método del codo y coeficiente Silhouette para seleccionar K en K-means.




```
Cantidad de registros analizados: 1134
Distancia mínima: 0.0
Distancia máxima: 44.9745
```

Figura 4. Distancias al quinto vecino más cercano como apoyo para explorar eps en DBSCAN.